

TÜRKİYE CUMHURİYETİ
YILDIZ TEKNİK ÜNİVERSİTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



SPERM HÜCRELERİNİN MORFOLOJİLERİNİN DERİN
ÖĞRENME İLE SINIFLANDIRILMASI

15011091 – Kamil BAŞKUT
16011110 – Ömer Lütfü TORTUMLU

BİLGİSAYAR PROJESİ

Danışman
Dr.Öğr.Üyesi Hamza Osman İLHAN

Ocak , 2020

TEŞEKKÜR

Bu projede danışmanımız Dr. Hamza Osman 'ILHAN'a yol göstericiliğinden ve bizi yeni bilgilerle donattığı için teşekkür ederiz.

Kamil BAŞKUT
Ömer Lütfü TORTUMLU

İÇİNDEKİLER

KISALTMA LİSTESİ	v
ŞEKİL LİSTESİ	vi
TABLO LİSTESİ	vii
ÖZET	viii
ABSTRACT	ix
1 Giriş	1
2 Ön İnceleme	2
3 Fizibilite	5
3.1 Yasal Fizibilite	5
3.2 Teknik Fizibilite	5
3.2.1 Donanım Fizibilitesi	5
3.2.2 Yazılım Fizibilitesi	5
3.3 Ekonomik Fizibilite	5
3.4 İş Gücü ve Zaman Planlaması	6
4 Sistem Analizi	7
4.1 Veri Seti Analizi	7
4.1.1 HuSHeM Veri Seti	7
4.1.2 SMIDS Veri Seti	8
4.2 PyQt5 Designer[5]	8
4.3 Google Colab[6]	8
5 Sistem Tasarımı	9
5.1 Kullanılan Konvansiyonel Sinir Ağları	9
5.1.1 MobileNet	9
5.1.2 GoogleNet	10
5.1.3 Xception	10

5.2	Yazılım Tasarımı	11
6	Performans Analizi	12
6.1	Optimizer Testi	12
6.2	Aktivasyon Testi	12
6.3	Veri Çoğaltma	13
6.4	Confusion Matrix	13
6.4.1	Accuracy	14
6.4.2	Precision	14
6.4.3	Recall	14
7	Uygulama	16
7.1	Proje Arayüzü	16
7.1.1	1.Adım	16
7.1.2	2.Adım	17
7.1.3	3.Adım	17
8	Sonuç	18
	Referanslar	19
	Özgeçmiş	20

KISALTMA LİSTESİ

CASA	Computer Assisted Semen Analysis
CPU	Central Processing Unit
CNN	Convolutional Neural Network
DNN	Deep Neural Network
GPU	Graphics Processing Unit
HuSHeM	Human Sperm Head Morphology
RAM	Random Access Memory
ROI	Region Of Interest
SVM	Support Vector Machine
SMIDS	Sperm Morphology Image Data Set
TPU	Tensor Processing Unit
WHO	World Health Organization

ŞEKİL LİSTESİ

Şekil 3.1	İş Gücü ve Zaman Planlaması	6
Şekil 5.1	MobileNet Mimarisi	9
Şekil 5.2	GoogleNet Çalışma Mimarisi	10
Şekil 5.3	Xception Mimarisi	10
Şekil 5.4	Transfer Öğrenme Yazılım Tasarımı	11
Şekil 6.1	Confusion Matris	14
Şekil 6.2	SMIDS GoogleNet Sigmoid Sgd	14
Şekil 6.3	SMIDS GoogleNet Softplus Sgd	15
Şekil 6.4	HuSHeM GoogleNet Softplus Sgd	15
Şekil 6.5	HuSHeM Xception Sigmoid Adam	15
Şekil 7.1	Proje Arayüzü	16

TABLO LİSTESİ

Tablo 4.1	Veri Setleri Sınıf Bilgileri	8
Tablo 6.1	HuSHeM Veri Setinin Optimizer Testi	12
Tablo 6.2	SMIDS Veri Setinin Optimizer Testi	12
Tablo 6.3	HuSHeM Veri Setinin Aktivasyon Testi	13
Tablo 6.4	SMIDS Veri Setinin Aktivasyon Testi	13

SPERM HÜCRELERİNİN MORFOLOJİLERİNİN DERİN ÖĞRENME İLE SINIFLANDIRILMASI

Kamil BAŞKUT
Ömer Lütfü TORTUMLU

Bilgisayar Mühendisliği Bölümü
Bilgisayar Projesi

Danışman: Dr.Öğr.Üyesi Hamza Osman İLHAN

Kısırlık teşhisi dönemimizde hastanelerde sperm hücreleri incelenerek yapılmaktadır. Bu incelemede tek tek spermin hareketine, şekline ve toplam sayısına bakılmaktadır. Bu inceleme günümüz teknolojisi ile uzmanlar tarafından mikroskop ile manuel olarak yapılmaktadır. Yapılan inceleme uzun zaman almakta ve yüksek dikkat gerektirmektedir. Bu analizlerde hata payı yüksek olmakta ve sonuçların objektifliği tartışılmaktadır.

Bu çalışmada sperm morfolojik analizlerinin otonom şekilde gerçekleştirilebileceği derin öğrenme teknolojisi ile bir karar mekanizması oluşturulması hedeflenmektedir. Böylece ortaya çıkan sonuçların hata payını düşürerek gerçeğe daha yakın objektif sonuçların sunulması planlanmaktadır.

Anahtar Kelimeler: Derin öğrenme, görüntü işleme, veri çoğaltma, konvensiyonel sinir ağları, tenserflow, confusion matris, GoogleNet, Xception, MobileNet, HuSHeM, SMIDS, pyqt5

ABSTRACT

SPERM CELLS OF MORPHOLOGIES CLASSIFICATION WITH DEEP LEARNING

Kamil BAŞKUT

Ömer Lütfü TORTUMLU

Department of Computer Engineering

Computer Project

Advisor: Assist. Prof. Dr. Hamza Osman İLHAN

The diagnosis of infertility is made by examining the sperm cells in hospitals during this period. The analysis takes a long time and requires high attention. In these analyzes, the margin of error is high and the objectivity of the results is discussed.

In this study, it is aimed to establish a decision mechanism with deep learning technology in which sperm morphological analyzes can be performed autonomously. Thus, it is planned to reduce the margin of error of the resulting results to present more objective results closer to reality.

Keywords: Deep learning, transfer learning, conventional neural networks, keras, tensorflow, data augmentation, sperm image classification, confusion matrix, GoogleNet, Xception, MobileNet, HuSHeM, SMIDS, pyqt5

1

Giriş

Erkeklerde kısırlık teşhisi, hastanelerde sperm hücreleri incelenerek yapılmaktadır. Bu incelemede sperm hücrelerinin sayısına, şekline ve hareketine bakılmaktadır. Morfolojik analiz olarak geçen bu incelemeler, günümüzde uzmanlar tarafından mikroskop yardımıyla manuel olarak yapılmaktadır. Bu analizlerde hata payı yüksek olmakta ve sonuçların objektifliği tartışılmaktadır. Bu çalışmada laboratuvarlardan alınan iki farklı veri seti kullanılarak, sperm hücrelerin morfolojisi incelenmesi amaçlanmıştır. Veri setlerimiz farklı boyama teknikleriyle boyanmış olup, elde edilen bu resimlerin derin öğrenme ile eğitilerek morfolojik analizlerin otonom bir şekilde yapılması hedeflenmektedir. Böylece daha hızlı ve daha objektif sonuçlar sunulabilir. Bu alanda daha önceden yapılmış olan çalışmalar mevcuttur. Amacımız bu çalışmalarda elde edilen başarıları geçmek değildir, farklı ağları deneyerek 2 veri seti içinde kabul edilebilir bir başarımlar veren ortak bir ağ belirleyebilmek.

2 Ön İnceleme

Kısırlık, 1 yıllık düzenli cinsel ilişkiden sonra çocuk sahibi olamama olarak teşhis edilir. WHO raporlarına göre dünyadaki tüm çiftlerin 15%-20%'si bir çeşit kısırlık problemi yaşıyor. Bu sorunların nedeni temel olarak; i) erkek, ii) kadın, iii) açıklanmamış ve iv) çift tabanlı olarak sınıflandırılmaktadır.

Spermiyogram olarak da bilinen semen numune analizi, erkek faktörüne bağlı problemleri gözlemlemek için kısırlık tanısında en popüler testtir. İki adımda gerçekleştirilir i) Verilen semen örneği viskozite, renk ve koku gibi fiziksel görünümünden değerlendirilir. ii) Bir uzman, bilgisayarlı veya manuel değerlendirme tekniklerini kullanarak sperm özelliklerini, morfoloji, konsantrasyon ve motilite parametreleri açısından ölçer. Sperm morfolojisi analizi, sperm başı, orta parça ve kuyruk için boyutsal değerlendirmeye odaklanır. Anormalliklerin kısırlık üzerinde doğrudan etkisi vardır. WHO, insan sperm değerlendirmelerinde kılavuz olarak kullanılacak referans değerlerini rapor eder. 1980'de yayınlanan ilk baskıda, tüm sperm konsantrasyonu üzerindeki normal sperm yoğunluğu için referans oranı 80% olarak tanımlanmış, ancak daha sonra 2010 baskısında 4% olarak güncellenmiştir. Bu raporlar ayrıca sperm morfolojisinin kalitesinin hızla azaldığını göstermektedir.

Morfolojik analizden önce semen örneğinin hazırlanmasında, sperm şekillerinin görünürlüğünü artırmak için numune kimyasallarla boyanır. Daha sonra, örnek, bilgisayar tabanlı sistemlere göre daha ucuz ve daha pratik olan görsel değerlendirme tekniği olarak da bilinen manuel değerlendirme adımıyla bir uzman tarafından gözlemlenir. Bu nedenle, birçok laboratuvar hala testleri görsel değerlendirme tekniği ile gerçekleştirmektedir. Ancak, sonuçları güçlü bir şekilde etkilenir. Bu, analizin sonuçlarının değişebileceği gözlemci değişkenlik problemi olarak da bilinir. Alternatif olarak, analizlerde insan faktörlerini izole eden bilgisayar tabanlı sistemlerde testler yapılabilir. Bu tür bilgisayar tabanlı sistemler, CASA sistemleri olarak bilinir. Görsel analizle karşılaştırıldığında, CASA sistemi daha güvenilir, tutarlı ve nesneldir. Ancak, sistemin kurulum ve bakım maliyeti daha pahalıdır. Ek olarak, morfolojik analiz dikkate alındığında, CASA sistemleri birçok açıdan önemli gelişmeler gerektirir.

Bilgisayar tabanlı analiz sistemleri temel olarak iki ardışık adımdan oluşur. Belirli semen örneğinde sperm tespiti bir segmentasyon işlemidir ve analizin ilk adımını oluşturur. Daha sonra, her bir ROI yaması, sınıflandırma ve makine öğrenme teknikleri ile bir sınıfa (sperm olmayan, normal veya anormal sperm) atanmalıdır. Bu iki ana başlık altında literatürde farklı çalışmalar bulunmaktadır.

Sperm saptama adımında Olalla ve arkadaşları Otsu eşik ve dalgacık dönüşümünün bir kombinasyonunu kullanmıştır. Daha sonra, algılanan parçaların sınıflandırma adımında SVM kullandılar. Sadece normal ve anormal olarak etiketlenmiş akrozom kusurlarına odaklanan ikili bir sınıflandırma modeli oluşturdular.

Alegre ve diğerleri Sperm saptama adımında aynı yaklaşımı uyguladılar, ancak aynı veri kümesini normal ve anormal olarak değerlendirmek için Haralick ve Counter özelliklerini kullanarak farklı bir sınıflandırıcı modeli oluşturdular.

Khachane ve diğerleri sadece akrozom tabanlı anormallik yerine daha ayrıntılı sperm anormalliği sınıflandırması için bulanık kural tabanlı bir sınıflandırma tekniği sundu. Her sperm ayrı ayrı ayrıntılı kafa, orta parça ve kuyruk alt segmentlerine ayrıldı. Daha sonra, her bölümlere ayrılmış sperm parçasının blob analizi ile elde edilen uzamsal özellikler (majör ve minör eksenler, bölgesel alan vb.) Bulanık mantıksal ifadelerle dayalı sınıflandırma adımında kullanılmıştır. Chang ve diğ. sınıflandırıcı tasarımında kullanılmak üzere iki aşamalı özellik çıkarma şeması önerdi. Kümeleme fikrini histogram tabanlı renk alanı analizinde uyguladılar. Başka bir makalede, sperm morfolojik analizi için altın standart bir prosedür getirmeyi amaçladılar. Lekeli mikroskop görüntülerinden her sperm yamasını manuel olarak kırıp döndürdüler. Daha sonra yama özelliklerini elde etmek için şekil tabanlı tanımlayıcılar kullandılar. Naive Bayes, k En Yakın Komşu, Karar Ağacı ve SVM modelleri sınıflandırma sürecinin özellikleri ile eğitildi. Bu veri kümesi için performans 58 % olarak ölçüldü.

Benzer şekilde, Shaker ve arkadaşları ayrıca lekeli görüntülerden sperm yamalarını kırarak her sperm yamasını belirli bir yöne döndürdü. Daha sonra, SVM modelindeki dört anormalliği sınıflandırmak için sözlük öğrenme şeması kullandılar. Ayrıca tekniklerini Chang ve arkadaşlarının HuSHeM veri kümeleri için 92.2 % doğruluk elde ettiklerini bildirdiler.

Normal sperm başı eliptik bir şekil olarak modellenabilir. Sperm kafasını tespit aşamasında, Nafisi kuyruğun büyüklüğü ve varlığı için bir ölçüm kriteri önerdi. Başlığı parçalamak için eliptik bir maske oluşturdular. Tanıda farklı akrozom temelli alt anormallikler vardı. Nafisi baş sınır ekstraksiyonunun verimsiz olması nedeniyle çalışmalarındaki alt anormallikleri sınıflandıramadı. Gonzales-Castro ayrıntılı bir sperm başı analizi için havza segmentasyonu kullanılarak konvansiyonel Otsu eşiğini

değiştirmiştir. Bu yaklaşım, kafayı daha belirli bölgelerle tanımlamak için daha görünür sperm sınırları sağladı. Bununla birlikte, mikroskop optik yansımaları ve sperm oklüzyonları sınır tespitini etkiledi. Bu sorunun üstesinden gelmek için Bijar ve ekibi Naive Bayes sınıflandırıcısı kullanmıştır. Pikselleri arka plan, çekirdek ve akrozom olarak üç sınıfa ayırdılar. Sınıf tabanlı olasılık fonksiyonlarını elde etmek için Uyarlamalı Karışım Modelleri ve Markov rasgele alanı kullanılmıştır. Bu yaklaşımda oklüzyon ve halo etkileri başarıyla ortadan kaldırıldı, ancak normal sperm ile benzer bir şekle sahip olması nedeniyle sperm olmayan partiküllerin varlığı hala bir sorundu. Sperm / non-sperm olarak sınıflandırmak için çıkarılan parçaların sadece boyut bilgilerine odaklandılar. Sperm yapısına benzer şekillere sahip eserler ve enkazlar sınıf olasılıklarını etkiledi.

Bu çalışmada GoogleNet, Xception ve MobileNet olarak adlandırılan üç CNN, DNN sınıflandırıcıları olarak kullanılmıştır. Bu CNN'lerde, parçalı yamaların ham pikselleri bir DNN'nin ilk seviyesine beslenir ve bu katmanın çıktıları, olası sperm görüntülerinde çizgiler ve kenarlar gibi farklı düşük seviyeli özelliklerin varlığını temsil ettiği şeklinde yorumlanabilir. Spermier bu CNN'lerin sonraki katmanlarında, düşük seviyeli özellikler daha sonra şekil kümeleri halinde birleştirilen temel şekiller (kafa, bir sperm kuyruğu veya bir gürültü bileşeni) gibi daha yüksek seviyeli özelliklerin varlığının bir ölçüsünde birleştirilir. Ve son olarak, tüm bu bilgileri kullanarak, DNN'ler bu yüksek seviyeli özelliklerin belirli bir nesneyi içermesi olasılığı sağlayabilir. Tüm geleneksel özellik çıkarma ve geleneksel makine öğrenme yaklaşımları ile uçtan uca DNN tabanlı yaklaşımların elde edilen sınıflandırma performansları sunulmuş ve en düşük hesaplama maliyetinin eşlik ettiği en yüksek doğruluğa sahip iş akışı önerilen hibrit model olarak seçilmiştir.

3.1 Yasal Fizibilite

Proje kapsamında kullanılması planlanan Python[1], Keras[2], Pycharm[3] ve Anaconda'ya [4] ait geliştiricileri tarafından belirlenmiş olan kendi lisansları incellenmiş ve proje kapsamında kullanımlarına uygun bulunmuştur.

3.2 Teknik Fizibilite

3.2.1 Donanım Fizibilitesi

Proje kapsamında kullanılması planlanan keras kütüphanesi, öğrenme işlemleri için yüksek CPU gücüne ihtiyaç duymamaktadır. Çalışmalarımızı Google Colab üzerinden gerçekleştireceğimiz için, Google Colab bize gerekli donanımsal ortamı sağlayacaktır.

Projenin gerçekleştirileceği bilgisayarın system özellikleri.

İşlemci : Intel(R) Core(TM) i7-6700HQ CPU @ 2.60 GHz

RAM : 16 GB

Ekran kartı : NVIDIA GeForce GTX 950M

3.2.2 Yazılım Fizibilitesi


Proje windows 10 üzerinde gerçekleştirilecektir. Proje Python dilinde (Python 3.6) yazılacak ve tensorflow(GPU), keras kütüphaneleri kullanılacaktır. Keras python dilinde yazılmış yapay sinir ağları için kullanılan açık kaynaklı bir kütüphanedir. Çalışmalarımız Google Colab üzerinden gerçekleştirilecektir.

3.3 Ekonomik Fizibilite

Projede ekonomik olarak değerlendirecek bir gider bulunmamaktadır.

3.4 İş Gücü ve Zaman Planlaması

Proje kapsamında önce eldeki verilerin belirlenen formatta incelenmesi, ardından çeşitli önışlemler ve sentetik veri üretme metodları kullanılarak elde edilen veri setleri üzerinde çalışılması planlanmıştır.



Şekil 3.1 İş Gücü ve Zaman Planlaması

4

Sistem Analizi

Gerçeklenmesi planlanan sistemde verilerin sınıflandırılması için derin öğrenme metotları kullanılacaktır. Proje süresince çeşitli derin öğrenme metotları test edilip, HuSHeM ve SMIDS veri setleri için başarı oranı yüksek olan metotlar bulunması planlanmaktadır. Proje kapsamında sadece tek bir veri seti için yüksek başarı gösteren değil, her iki veri seti için yüksek başarı gösteren daha genel bir metot bulunması amaçlanmaktadır. Projede kullanılması planlanan metotlar Python üzerinden çalışan keras kütüphanesi ile gerçekleştirilecektir. Keras; TensorFlow, CNTK veya Theano üzerinde çalışan; Python dilinde yazılmış yüksek seviyeli bir sinir ağı uygulama programlama arayüzüdür. Proje kapsamında veri setlerinin MobileNet, GoogleNet ve Xception ağlarında test edilmesi planlanmaktadır. Test edilmesi planlanan ağlar doğrudan keras üzerinden kullanılacaktır. Bu ağlarda özellikle karar katmanındaki optimizasyon ve aktivasyon fonksiyonu gibi parametreler test edilecektir. Bu parametreler içerisinde en başarılı sonuçları veren parametrelerin bulunması hedeflenmektedir.

4.1 Veri Seti Analizi

Bu çalışma sırasında HuSHeM ve SMIDS veri seti üzerinde çalışmalar yürütülecektir. Veri setleri önceden elle eğitim ve test verilerine ayrılarak 5 farklı dosya oluşturulmuştur.




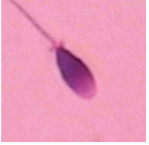

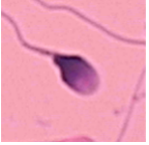
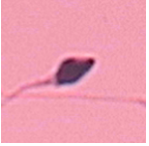
4.1.1 HuSHeM Veri Seti

HuSHeM(Human Sperm Head Morphology) veri seti 4 sınıflı bir yapıda olup bu sınıflar: normal, tapered, pyriform ve amorphous şeklinde belirlenmiştir.

4.1.2 SMIDS Veri Seti

SMIDS(Sperm Morphology Image Data Set) veri seti ise 3 sınıflı bir yapıya sahiptir ve bu sınıflar: normal sperm, abnormal sperm ve non-sperm olarak ayrılmıştır.

Tablo 4.1 Veri Setleri Sınıf Bilgileri

SMIDS			HuSHeM		
	Normal	1021	Normal	54	
	Abnormal	1005	Tapered	53	
	Non-Sperm	974	Pyriform	57	
			Amorphous	52	
	Toplam	3000	Toplam	216	

4.2 PyQt5 Designer[5]

PyQt5, uygulamamızı tasarlamamız için basit bir tasarımcı uygulama ile gelir. PyQt5'yi Windows'a kurduğunuzda modüle ek olarak Qt Designer, Qt Linguist ve Qt Assistant ve bir kaç tane işe yarar betikle gelir. Bu betikte ön yüzü tasarladıktan sonra ile çıkan başarılı ağlarla bağlama işlemleri yapılmıştır.

4.3 Google Colab[6]

Python programlama diliyle Keras[2], TensorFlow, PyTorch ve OpenCV gibi kütüphaneleri kullanarak derin öğrenme (deep learning) uygulamaları geliştirilebilir. Colab'ı diğer bulut servislerinden ayıran en önemli özellik; Colab'ın ücretsiz GPU sağlamasıdır.

5.1 Kullanılan Konvensiyonel Sinir Ağları

Deep learning ile görüntü sınıflandırması yaparken keraski, IMAGENET üzerinden geliştirilen modelleri kullanarak kendi veri setlerimizde transfer learning işlemi uygulayacağız.

5.1.1 MobileNet


MobileNet[7], hesaplama gücünün olmadığı mobil ve gömülü tabanlı görsel uygulamalar için daha uygun bir modeldir. Model Google tarafından geliştirildi. Ağlarda karşılaştırıldığında aynı derinliğe sahip normal konvolüsyonlarla, ağı kıyasla parametre sayısını önemli ölçüde azaltan derinlemesine ayrılabilir evrişimler kullanır. Model 91 katmandan oluşur.

Type / Stride	Filter Shape	Input Size
Conv / s2	$3 \times 3 \times 3 \times 32$	$224 \times 224 \times 3$
Conv dw / s1	$3 \times 3 \times 32 \text{ dw}$	$112 \times 112 \times 32$
Conv / s1	$1 \times 1 \times 32 \times 64$	$112 \times 112 \times 32$
Conv dw / s2	$3 \times 3 \times 64 \text{ dw}$	$112 \times 112 \times 64$
Conv / s1	$1 \times 1 \times 64 \times 128$	$56 \times 56 \times 64$
Conv dw / s1	$3 \times 3 \times 128 \text{ dw}$	$56 \times 56 \times 128$
Conv / s1	$1 \times 1 \times 128 \times 128$	$56 \times 56 \times 128$
Conv dw / s2	$3 \times 3 \times 128 \text{ dw}$	$56 \times 56 \times 128$
Conv / s1	$1 \times 1 \times 128 \times 256$	$28 \times 28 \times 128$
Conv dw / s1	$3 \times 3 \times 256 \text{ dw}$	$28 \times 28 \times 256$
Conv / s1	$1 \times 1 \times 256 \times 256$	$28 \times 28 \times 256$
Conv dw / s2	$3 \times 3 \times 256 \text{ dw}$	$28 \times 28 \times 256$
Conv / s1	$1 \times 1 \times 256 \times 512$	$14 \times 14 \times 256$
5x	Conv dw / s1	$3 \times 3 \times 512 \text{ dw}$
	Conv / s1	$1 \times 1 \times 512 \times 512$
	Conv dw / s2	$3 \times 3 \times 512 \text{ dw}$
	Conv / s1	$1 \times 1 \times 512 \times 1024$
	Conv dw / s2	$3 \times 3 \times 1024 \text{ dw}$
	Conv / s1	$1 \times 1 \times 1024 \times 1024$
	Avg Pool / s1	Pool 7×7
	FC / s1	1024×1000
	Softmax / s1	Classifier

Şekil 5.1 MobileNet Mimarisi

5.1.2 GoogleNet


GoogLeNet (Inception V3)[8], veri setlerindeki çeşitlilik nedeniyle oluşan doğru çekirdek boyu seçme problemine bir çözüm getirmeye çalışmıştır. Bu soruna çözüm olarak Şekilde gözüktüğü gibi birden fazla farklı boyuttaki ltre yi aynı katmanda çalıştırıp çıktıları birleştirme yaklaşımına gitmiştir. GoogLeNet'te 1×1 evrişim, hesaplamayı azaltmak için boyut küçültme modülü olarak kullanılır. Hesaplama darboğazı azaltılarak derinlik ve genişlik artırılabilir.



Şekil 5.2 GoogleNet Çalışma Mimarisi


5.1.3 Xception

Xception[9], standart Inception modüllerini derinden ayrılabilen konvolüsyonlarla değiştiren Inception mimarisinin bir uzantısıdır.



Şekil 5.3 Xception Mimarisi

5.2 Yazılım Tasarımı



Şekil 5.4 Transfer Öğrenme Yazılım Tasarımı

6

Performans Analizi

6.1 Optimizer Testi

Projede ağılar farklı 7 optimizer ile test edilmiştir. Bu testlerden çıkan en iyi 3 sonuç ile analizler gözlemlenmiştir. Bu analizler sonucunda HuSHeM veri setinde GoogleNet için sgd, Xception için adam, MobileNet için adamax optimizerları en yüksek başarımlarını vermişlerdir.

Aşağıdaki tabloda HuSHeM veri setinin optimizer sonuçlarını göstermektedir. Bu veriseti GoogleNet, Xception ve MobileNet ağıları için 10 epochta test edilmiştir.

Tablo 6.1 HuSHeM Veri Setinin Optimizer Testi

	GoogleNet	Xception	MobileNet
Sgd	72% (Softmax)	70% (Softplus)	68% (Softplus)
Adam	55% (Softplus)	74% (Sigmoid)	64% (Softmax)
Adamax	72% (Softplus)	71% (Softplus)	70% (Softplus)

Aşağıdaki tabloda SMIDS veri setinin optimizer sonuçlarını göstermektedir. Bu veriseti GoogleNet, Xception ve MobileNet ağıları için 10 epochta test edilmiştir.

Tablo 6.2 SMIDS Veri Setinin Optimizer Testi

	GoogleNet	Xception	MobileNet
Sgd	85% (Sigmoid)	86% (Sigmoid)	84% (Softplus)
Adam	69% (Softplus)	82% (Softmax)	73% (Softplus)
Adamax	83% (Sigmoid)	87% (Sigmoid)	84% (Softplus)

6.2 Aktivasyon Testi

Projede ağılar oluşturulurken son karar katmanlarında kullanılan aktivasyon fonksiyonlarının her iki veri seti için de ayrı ayrı sonuçları gösterilmektedir. Bu metnin devamında da gösterilecek sonuçlar ve yorumlar veri setlerini birbirinden bağımsız olarak ele alınacaktır.

Aşağıdaki tabloda HuSHeM veri setinin aktivasyon sonuçlarını göstermektedir Bu veriseti GoogleNet, Xception ve MobileNet ağıları için 10 epochta test edilmiştir.

Tablo 6.3 HuSHeM Veri Setinin Aktivasyon Testi

	GoogleNet-sgd	Xception-adam	MobileNet-adamax
Softmax	72%	65%	60%
Softplus	71%	65%	70%
Sigmoid	71%	74%	36%

Aşağıdaki tabloda SMIDS veri setinin aktivasyon sonuçlarını göstermektedir Bu veriseti GoogleNet, Xception ve MobileNet ağıları için 10 epochta test edilmiştir.

Tablo 6.4 SMIDS Veri Setinin Aktivasyon Testi

	GoogleNet-sgd	Xception-adam	MobileNet-adamax
Softmax	79%	82%	76%
Softplus	84%	80%	84%
Sigmoid	85%	74%	37%

6.3 Veri Çoğaltma

Elde edilen sonuçların doğruluk oranlarını arttırmak için veri çoğaltma metodları kullanılmıştır. Bu metodlar görselleri döndürme, kesme, gürültü ekleme gibi metodlarla farklılaştırmaktadır. Bu testlerin sonucunda eldeki sınırlı veriye rağmen daha yüksek başarımlar elde edilmesi amaçlanmış ve ağların verileri ezberlemesinin önüne geçilmek istenmiştir.

6.4 Confusion Matrix

Confusion matrisi tahminlerin doğruluğu hakkında bilgi vermesi için kullanılmıştır. Confusion matris ile tahmin edilen resimlerin hangi sınıfa ait olduğunu ve hangi sınıflara benzetildiğinin görülmesi planlanmaktadır. Bu çalışmada Confusion matris accuracy, precision ve recall hesaplamalarında kullanılmıştır.

6.4.1 Accuracy

Doğru tahminlerin tüm test sınıfına oranıdır. Ağımızın veri setindeki başarısını ifade etmek için kullanılmıştır.

6.4.2 Precision

Tüm sınıflardan, doğru tahmin edilen sınıf sonuçlarını belirtir. Modelin doğruları bilme oranını hesaplamak için kullanılmıştır.


6.4.3 Recall

Tüm pozitif sınıflardan, doğru tahmin edilen sınıf sonuçlarını belirtir.

Dataset	Network	Activation	Optimizer	Accuracy	Precision	Recall
HuSHeM	GoogleNet	Softplus	sgd	72	0.72	0.75
	Xception	Sigmoid	adam	73	0.73	0.79
SMIDS	GoogleNet	Sigmoid	sgd	87	0.87	0.88
	GoogleNet	Softplus	sgd	83	0.83	0.87

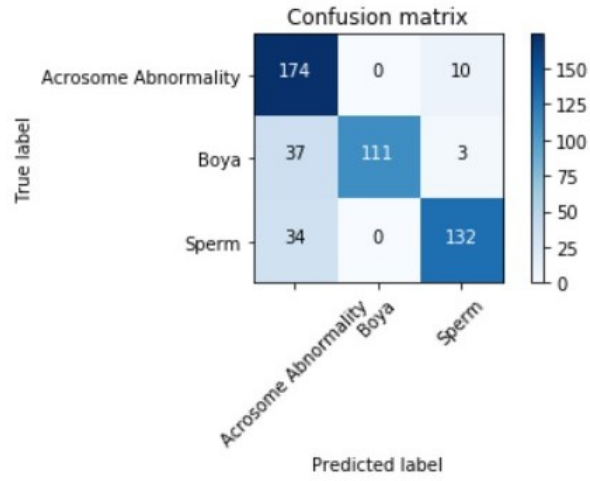
Şekil 6.1 Confusion Matris

SMIDS veri setinin GoogleNet ağında Sigmoid ve Sgd parametreleriyle confusion matris sonuçları aşağıda verilmiştir. SMIDS veri setinin GoogleNet ağında Softplus

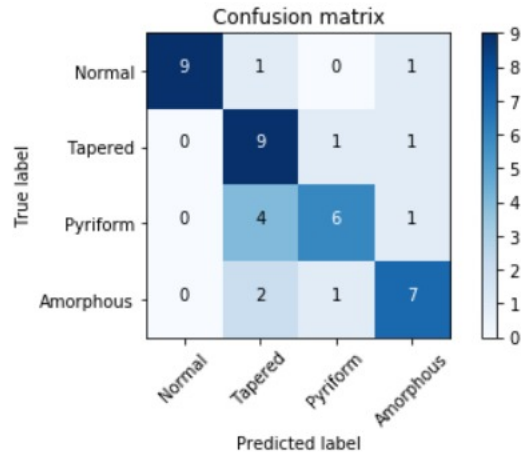


Şekil 6.2 SMIDS GoogleNet Sigmoid Sgd


ve Sgd parametreleriyle confusion matris sonuçları aşağıda verilmiştir. HuSHeM veri setinin GoogleNet ağında Softplus ve Sgd parametreleriyle confusion matris sonuçları aşağıda verilmiştir. HuSHeM veri setinin Xception ağında Sigmoid ve Adam parametreleriyle confusion matris sonuçları aşağıda verilmiştir.



Şekil 6.3 SMIDS GoogleNet Softplus Sgd




Şekil 6.4 HuSHeM GoogleNet Softplus Sgd



Şekil 6.5 HuSHeM Xception Sigmoid Adam

7.1 Proje Arayüzü



Şekil 7.1 Proje Arayüzü

7.1.1 1.Adım

Bu adımda, veriseti ve bu verisetinde çalışılmış olan ağın en başarılısı seçilmiştir. Arayüzde seçilen ağın veriseti ile en başarılı olduğu parametrelerde colab'da test yapılmış ve confusion matrisi ve model ağırlıkları çıkartılmıştır. Yapılan seçim ile model ağırlıkları yüklenip, confusion matrisi kullanıcıya gösterilmektedir.

7.1.2 2.Adım

Bu adımda test edilmek istenen fotoğraf kullanıcı tarafından el ile dosya yolu girilerek veya browse butonuna basarak seçilir load test image butonuyla seçilen fotoğraf yüklenir.Model de test edilebilmesi için fotoğrafın eğitilen model boyutlarına dönüştürülmesi gerekmektedir. HuSHeM veri seti seçildiğinde fotoğraf 131x131, SMIDS veri seti içinde 170x170 boyutlarına dönüştürülmektedir.

7.1.3 3.Adım

Bu adımda yüklenen fotoğraf test edilir. Veriseti için bulunan sınıf benzerlik sonuçları yazı kutusuna yazılır. En yüksek sonuç fotoğrafın en yakın olduğu sınıftır soru işaretli bölüme sınıf ismi yazılır.

8 Sonuç

Bu çalışma kapsamında HuSHeM ve SMIDS veri setleri Xception, GoogleNet ve MobileNet ağıları üzerinde test edilmiştir. Ağlar üzerinde sırasıyla optimizer ve aktivasyon parametrelerinin testi, veri çoğaltma testi ve epoch testi uygulanmıştır. GoogleNet ağının test edilen veri setlerinde Xception ve MobileNet ağlarına oranla daha iyi başarımlar gösterdiği gözlemlenmiştir. Parametre testlerinde en yüksek başarıyı gösteren 2 parametre için veri çoğaltma testleri gerçekleştirilmiş ve ağların en yüksek başarımlarını gösterdiği veri çoğaltma metodları tespit edilmiştir. Bu çoğaltmalarda artım 1%-3% oranında olduğu gözlemlenmiş belli bir noktadan sonra düştüğü gözlemlenmiştir. Çalışmalar sonucunda ağlara ve verisetlerine göre bulunan en yüksek başarımlarının ayarlanmış parametreleri optimizer olarak sgd aktivasyon olarak softplus olarak gözlemlenmiştir.

- [1] P. S. Foundation. (). Python is a programming language, [Online]. Available: <https://www.python.org/> (visited on 11/04/2019).
- [2] K. Team. (). The python deep learning library, [Online]. Available: <https://keras.io/>. (visited on 11/04/2019).
- [3] JetBrains. (). The python ide for professional developers by jetbrains, [Online]. Available: <https://www.jetbrains.com/pycharm/> (visited on 11/04/2019).
- [4] A. Inc. (). The world's most popular data science platform, [Online]. Available: <https://www.anaconda.com/> (visited on 11/04/2019).
- [5] Tim. (). PyQt5 designer tutorial, [Online]. Available: <https://techwithtim.net/tutorials/pyqt5-tutorial/how-to-use-qtdesigner/> (visited on 12/10/2019).
- [6] A. Bonner. (). Google colab tutorial, [Online]. Available: <https://towardsdatascience.com/getting-started-with-google-colab-f2fff97f594c> (visited on 12/10/2019).
- [7] G. Inc. (2017). Mobilenets: Efficient convolutional neural networks for mobile vision applications, [Online]. Available: <https://arxiv.org/pdf/1704.04861.pdf> (visited on 11/04/2019).
- [8] Google. (2014). Going deeper with convolutions, [Online]. Available: <https://arxiv.org/pdf/1409.4842v1.pdf> (visited on 11/04/2019).
- [9] F. Chollet. (2017). Xception: Deep learning with depthwise separable convolutions, [Online]. Available: <https://arxiv.org/pdf/1610.02357v3.pdf> (visited on 11/04/2019).

BİRİNCİ ÜYE

İsim-Soyisim: Kamil BAŞKUT
Doğum Tarihi ve Yeri: 11.11.2011, İstanbul
E-mail: kamil.baskut1@gmail.com
Telefon: 0541 925 61 60
Staj Tecrübeleri: ABCDE Şirketi Yazılım Departmanı

İKİNCİ ÜYE

İsim-Soyisim: Ömer Lütfü TORTUMLU
Doğum Tarihi ve Yeri: 08.09.1997, Erzurum
E-mail: omertortumlu@gmail.com
Telefon: 0535 877 39 89
Staj Tecrübeleri: Uyumsoft A.Ş. ,Uyumakademi

Proje Sistem Bilgileri

Sistem ve Yazılım: Windows İşletim Sistemi, Python
Gerekli RAM: 2GB
Gerekli Disk: 256MB